Projekt: Rozpoznanie Cyfer Napisanych Długopisem Elektrycznym

Vitalij Syrotynskyi, Katrych Oleksandr

Opis zadania i zbioru danych

Zbierano dane o cyferkach ręcznie pisanych przez 44 osoby (ok. 250 od każdej osoby). Cyferki pochodzące od 30 osób użyto do treningu, a cyferki pochodzące od 14 innych użytodo testu. Cyferki zostały pisane na specjalnym urządzeniu o rozdzielczości 500 × 500, pozwalającym zapamiętaćkolejne współrzędne (x, y) długopisu w 100-milisekundowych odstępach czasowych. Po zastosowaniu skalowania i normalizacji, współrzędne (x, y) przekształcono na wartości z przedziału [0; 100].

Opis zbioru danych

Nazwa pliku	Liczba rekordów	Liczba atrybutów	Opis atrybutów
pendigits.tra (Training)	7494	16 input+1 class attribute	16 integer[0;100] 1 class attribute [0;9]
pendigits.tes (Testing)	3498	16 input+1 class attribute	16 integer[0;100] 1 class attribute [0;9]

Klasa decyzyjna	Ilość przykładów w ‘training set’
0	780
1	779
2	780
3	719
4	780
5	720
6	720
7	778
8	719
9	719

Klasa decyzyjna	Ilość przykładów w ‘testing set’
0	363
1	364
2	364
3	336
4	364
5	335
6	336
7	364
8	336
9	336

Opis algorytmu, narzędzie programistyczne

Program napisany w jeżyku : `Java 8`

Stosowano **algorytmu wstecznej propagacji błędu**. Jest to podstawowy algorytm uczenia

nadzorowanego wielowarstwowych jednokierunkowych sieci neuronowych. Podaje on rzepis na zmianę wag w_{ij} dowolnych połączeń elementów przetwarzających rozmieszczonych w sąsiednich warstwach sieci. Oparty jest on na minimalizacji sumy kwadratów błędów uczenia z wykorzystaniem optymalizacyjnej metody największego spadku.

Algorytm uczenia

Krok 1: Wylosuj początkowe macierze wag `W, V` i początkowe wektory odchyleń `B, C`

Krok 2: Dla każdego wektora uczącego `X`

2.1 Wyznacz wektor wyjściowej z I warstwy (ukrytej) $Y = f(W.X + B)$

2.2 Wyznacz wektor wyjściowej z II warstwy (wyjściowej) $Z = f(V.Y + C)$

2.3 Wyznacz błędy neuronów

a) Warstwa wyjściowa: $\delta_k = f'(net_k)(d_k - y_k)(dla \quad k = 1, 2, \ldots, K)$

b) Warstwa ukryta: $p_j = f'(net_k)\sum_{k=1}^{K} v_{kj}\delta_k \quad (dla \quad j = 1, 2, \ldots, J)$

2.2 Aktualizuj wagi `(dla i = 1,...,K)`

a) Warstwa wyjściowa:

$V^k{}_{new} = V^k{}_{old} + \eta\delta_k Y \quad (dla \quad k = 1, 2, \ldots, K)$

$c^k{}_{new} = c^k{}_{old} + \eta\delta_k$

b) Warstwa ukryta:

$W^j{}_{new} = W^j{}_{old} + \eta p_j X \quad (dla \quad j = 1, 2, \ldots, J)$

$b^j{}_{new} = b^j{}_{old} + \eta p_j$

Krok 3: Jeśli wagi pozostały bez zmian lub `E < E min` to stop, wpp. powrót do Krok 2

Do rozwiązania problemu było stosowano trzywarstwową sieć neuronową.

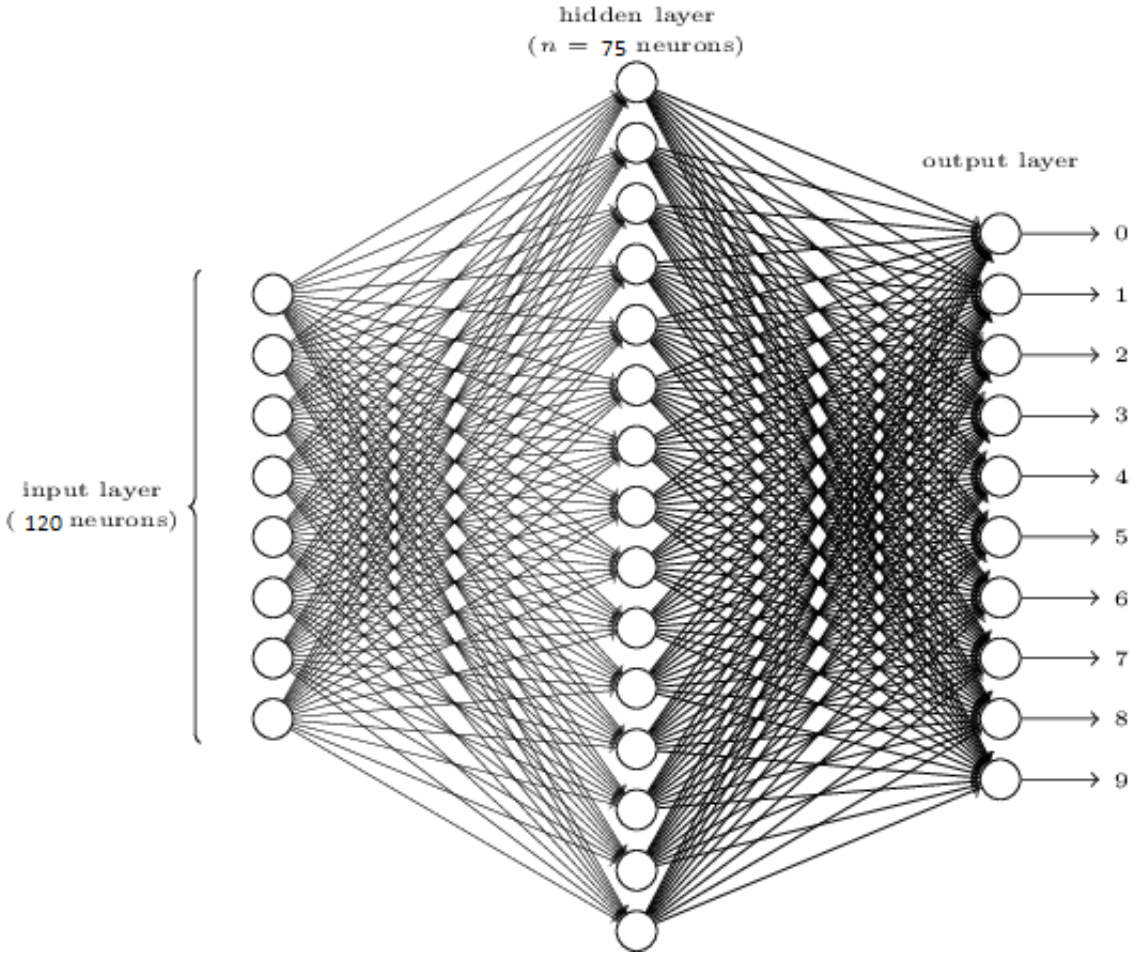

Wagi początkowe losowane w przedziale `[-1;1]`.
Przy testowaniu sieci było obrano **współczynnik uczenia** – `0.25`.
Liczba epok – `30`.

Przygotowanie danych do eksperymentu

Dane eksperymentalne, za pomocą jeżyka `Java`, były wczytane z pliku do macierzy : `double[][]`
Dane treningowe było podzielono na 3 części. Pierwsza polowa dla uczenia sieci. Jedna czwarta dla walidacji. Jedna czwarta dla testów uzależnionych od pisarzy. Dane testowę zostały wykorzystane do testowania sieci i oceniania jakości modelu.

Metoda oceniania jakości modelu

$E = \frac{1}{2}\sum_{i=1}^{P}\sum_{j=1}^{K}(d_i^{(j)} - y_i^{(j)})^2$
W końcowym wyniku udało się zdobyć **95%** poprawności sieci na danych testowych.

Wyniki eksperymentalne

W trakcie pracy nad algorytmem najpierw było stosowano sieci dwuwarstwowej, ale wyniki testowania nie przekracały **55-65%** poprawności.

Dalej było zaimplementowano trzywarstwową sieć i wyniku zmieniania neuronów na 1 i 2 warstwie, liczb epok i współczynnika uczenia udało się zdobyć **95%** poprawności sieci na danych testowych.

Algorytm wczytywania namalowanej(w naszym programie) cyfry

Przestrzeń dla rysowania `PaintArea` zrobiona za pomocą `JPanel`, nie jest bardzo fajnym narzędziem do rysowania (jeśli za szybko rysować to cyfry nie będzie widać), ale dla naszego eksperymetu tego jest wystarczająco. Został dodany nowy `MouseMotionListener` i teraz kiedy przeciskamy i poruszamy myszką to się wywoła metoda `mouseDragged(MouseEvent e)`, w niej zapisujemy pozycję myszki w wektor współrzędnych (x, y) w naszym przypadku to `ArrayList<Pair<Integer, Integer>> digitVector` i równocześnie rysujemy na wykresie. Kiedy zakończymy przesuwać myszką wywoła się metoda `mouseReleased(MouseEvent e)` w której wywołamy metodę `Tools.compressVector(digitVector)` i otrzymujemy zkompresowany vektor (8 par współrzędnych (x, y)).

Algorytm kompresowania wektora namalowanej (w naszym programie) cyfry

Algorytm jest wykonany w metodzie `Tools.compressVector(digitVector)`. Najpierw otrzymane współrzędne (x, y) potrebno rozszerzyć tak, żeby cyfra mieściła się na krajach macierzy 100x100 (uczenie sieci wykonane na podobnych cyfrach). Przykład :

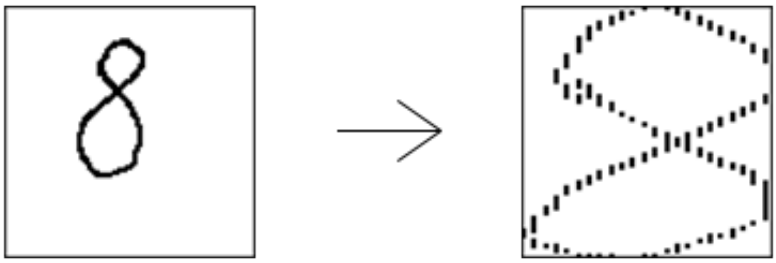

Następnie potrzebnym jest zmniejszenie liczby współrzędnych (x, y) do ośmiu (takie cyfry były wykorzystane dla uczenia sieci). Najpierw liczymy długość między wszyskimi współrzędnymi (x, y) za pomocą wzoru $d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$, który został zaimplementowany w metodzie `calcDigitLength(Vector)`. Dalej dzielimy otrzymaną długość na 7 równych odcinków (7 poniważ ósmy to jest pierwzy punkt), otrzymujemy długość `X`. Szukamy 8 punktów (współrzędnych) ze długością między nimi równej `X`. Przykład :

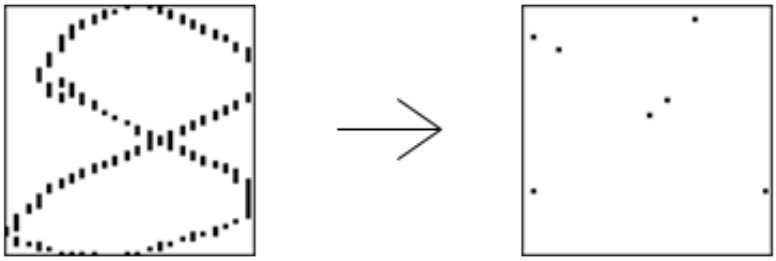

Własne komentarze, wnioski.

Oprócz samego algorytmu uczenia sieci i testowania jej na danych testowych było zaimplementowano okno dla wprowadzenia (rysowania) liczb za pomocą myszki komputerowej. Algorytm stosowany dla wybrania 16 atrybutów opisany powyżej.